



# 鲲鹏920体系结构特点及性能优化点

### 性能优化点 实施手段 鲲鹏920规格 速度快 **编程语言:** c/c++、汇编 指令级并行(去除指令间的依赖关系) 向量化并行(NEON) 指令集: ARMv8-A, ARMv 8.2 实施手段例: 循环并行化(串行循环转化为并行循 64C/64T,48C/48T 1.编译器自动优化: Cpu 2.6GHz 环) (1)编译选项: 多线程编程等 寄存器 31个通用寄存器 O2,O3,循环展开,自动向量化, 32个128bit的向量寄存器 (2)去掉全局变量便于编译器优 I Cache Size: 64KB 指令对齐 D Cache Size:64KB 预取 (3)受限的指针运用 CacheLine:64B Cache line 对齐 L1Cache 2.算法和数据结构 (1)数据组织(如:缓存利用) (2)算法实现的策略(如:查表) 预取 3.函数 Cache Size:512KB Cache line 对齐 L2Cache (1)传参设计 Cache Line:64B Cache分片 (2)内联小函数 4.循环 预取 展开、累积、拆分、合并 Cache Size:1MB/Core Cache line 对齐 5.语句 Cache Line:128B L3Cache Cache分片 避免生成不需要的指令,让语 线程级存储 句生成更高效的指令 避免false-sharing (FMA, Move指令排布) 使用高吞吐量的指令 内存通道:8x2933MT/s 7.多核并发 多线程编程 内存 Numa编程 内存重用 辅助:性能分析工具



容量大

# 算法和数据结构优化指南 之 对齐cacheline

优化示例: 1. 假设是行列数相同(M)的float方阵相乘。2. 为说明简单起见,假设M为items的倍数

# #define M 1600 for(int i=0; i < M;i++) { for(int j=0;j < M;j++) { dest[i][j] = 0; for(int k=0; k < M;k++) { dest[i][j] += src1[i][k] \* src2[k][j]; } } }

### 优化前性能

```
4,444,887,982 cache-misses
79.208280470 seconds time elapsed
79.085865000 seconds user
0.015972000 seconds sys
```

### 优化后代码

```
#define M 1600
#define CacheLineSize 64
int items = CacheLineSize / sizeof(float);
for(int i=0;i < M;i++) {
    for(int j=0;j < M;j += items ) {
        for(int jj=0;jj < items; jj++) {
            dest[i][j+jj] = 0;
        }
        for(int k=0;k < M;k++) {
            for(int jj=0;jj < items; jj++) {
                dest[i][j+jj] += src1[i][k] * src2[k][j+jj];
            }
        }
     }
}</pre>
```

### 优化后性能

Cache miss降低。运行时间降低一半

```
298,703,303 cache-misses
40.429041360 seconds time elapsed
40.366073000 seconds user
0.007988000 seconds sys
```

### 核心方法:

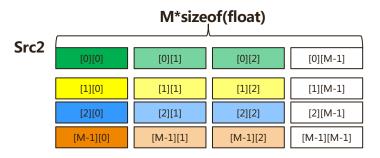
处理数据量对齐鲲鹏920 cache line(L1 L2 64B), 提升cache命中率

### 优化说明:

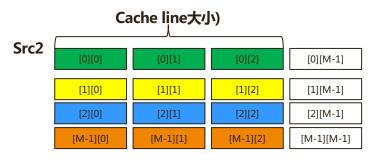
[优化前]

如图所示,同色系代表cacheline预期进来的数据,带有透明色的 代表被浪费的数据。

在M很大的情况下,如果M\*sizeof(float)大于cache line,则每次访问src2[k][i]都不能命中缓存。



### [优化后] Cache友好,不浪费cache line预取进来的数据





# 算法和数据结构优化指南 之 Cache分片

优化示例: 1. 假设是行列数相同(M)的float方阵相乘。2. 为说明简单起见,假设指定T能为M整除的倍数

# #define M 1600 for(int i=0; i < M;i++) { for(int j=0; j < M;j++) { dest[i][j] = 0; for(int k=0; k < M;k++) { dest[i][j] += src1[i][k] \* src2[k][j]; } } }</pre>

优化前代码片段

### 优化前性能

```
Performance counter stats for './block_gemm':
4,444,226,429 cache-misses
79.091859780 seconds time elapsed
78.976563000 seconds user
0.011981000 seconds sys
```

### 优化后代码片段

```
int T = 64;//
int N = M/T://25
int k = 0:
int i = 0:
int i = 0:
for(int kt = 0; kt < N; ++ kt){
  for(int it=0; it<N; ++it){
     for(int jt=0; jt<N; ++jt){
        int ktt = kt*T;
        int itt = it*T;
        int itt = it*T;
        for(k = ktt; k < ktt + T; + + k)
          for(i = itt; i < itt + T; ++i){
             float r = src1[i][k];
             for(j=jtt; j< jtt+T; ++j){
                dest[i][i] += r *src2[k][i];
```

### 优化后性能

Cache miss降低。运行时间降低一半以上

```
Performance counter stats for './block_gemm 64':
13,388,096 cache-misses
26.934739940 seconds time elapsed
26.893215000 seconds user
0.011983000 seconds sys
```

### 核心方法:

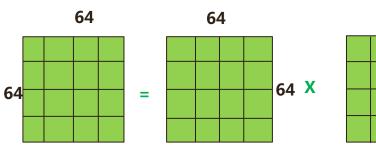
当计算量大的时候,进行分片,将计算量限定在 cache容量以内,降低cache miss以提升计算性能

### 优化说明

矩阵大小1600\*1600\*sizeof(float)\*3 Byte = 29.2M 超过了Cache的容量

### 将分块调整为

64\*64\*3\*sizeof(float) = 48K 在L1CacheSize 64KB以内





64

64

# 算法和数据结构优化指南之查表

### 核心方法:

- (1)如果某些运算频繁的进行,可以提前保存所有的可能的结果。运算时通过查表获取结果即可。查表法可获得性能提升
- (2)可结合查表法和线性插值法达到精度和性能的平衡。

```
      优化前代码
      优化后代码

      for(int j = 0; j < 100000000; j + +) {
            float val = expf(j%5);
        }
      </td>
      float a[5] = {2.71828,7.389,20.085,54.5981,148.413};
        for(int j = 0; j < 1000000000; j + +) {
                float val = a[j%5];
        }
      </td>

      优化后性能
            运行时间降低2/3

      0.978498000 seconds time elapsed
            0.978498000 seconds user
            0.000000000 seconds sys
```

VML的vexp、VSL的vRang中均实践了查表法。



# 函数优化指南之传参

# 优化前代码 struct WordModel { int x[100]; float y[20]; float z[10]; float getY0ByVal(WordModel bs) return bs.y[0]; int main(int argc, char \*\*argv){ WordModel val: for(int j = 0; j < 100000000; j + +) { float y0 = getY0ByVal(val); return 0; 优化前性能 2.019290750 seconds time elapsed 2.017644000 seconds user 0.000000000 seconds sys

```
优化后代码
struct WordModel {
  int x[100];
  float y[20];
  float z[10];
float getY0ByPtr(WordModel* bs)
  return bs->y[0];
int main(int argc, char **argv){
  WordModel val:
  for(int j = 0; j < 100000000; j + +) {
       float y0 = getY0ByPtr(&val);
return 0;
优化后性能
0.208923610 seconds time elapsed
0.208749000 seconds user
0.000000000 seconds sys
```

### 核心方法:

函数参数优先通过寄存器传递,大小超量通过 栈传递。

如果参数是大结构体或者类时,会有调用时的复制开销和返回时的销毁开销。

改成指针传递则只需要传递一个指针即可。开 销较小。

### 此为通用的优化方法



# 函数优化指南 之内联小函数

# 示例 //求0-9的平方 **inline** int inlineFunc(int num) if(num>9||num<0){ return -1; return num\*num; int main(int argc,char\* argv[]) int a=8: int res=inlineFunc(a); cout < < "res:" < < res < < endl;

# 优点:

- (1)消除函数调用的开销。
- (2)如果函数调用在循环体内,则编译器很难进行向量化。此时循环体内调用的函数如果采用内联形式的话,则编译器可识别优化

# 缺点:

如果内联后的函数较长,会增加寄存器压力 如果函数内有分支,内联后会对指令流水线产生不利影响



# 循环优化指南 之循环展开

### 原理知识:

- · 循环展开(Loop unroll)牺牲函数的尺寸,降低循环带来的开销,加快程序执行速度的方法;
- 针对Kunpeng 920处理器具有多个功能单元(FSU,ALU,LD/ST)的特点,循环展开也有利于充分使用功能单元进行指令级并行,优化指令流水线的调度。

### 使用方法:

- 针对循环之间不存在循环依赖或访问冲突的场景,可以使用SIMD改写、手工循环展开或者在编译选项中添加-funroll-loops;
- 针对循环之间存在依赖或访问冲突的场景,可以考虑手工循环展开的方式,减少循环开销。

### 注意:

- 小循环且内部没有判断逻辑,收益较高;
- 大循环展开有可能会引起通用寄存器的溢出,降低性能(寄存器重命名/ 外溢至内存);
- 内部有判断逻辑可能会增加分支预测的开销,需要具体情况具体分析。

```
#include <string.h
 oid vpow(int length, float* src)
   for (int i = 0; i < length; i++) {
       powf(src[i], src[i]);
   main(int argc, char **argv)
   float *src = (float *)malloc(1000000 * sizeof(float*))
   for (int i = 0; i < 10000000; i++) {
       src[i] = rand() * 100;
   vpow(1000000, src);
[100383570@localhost test opti]$ perf stat ./vexp
                                                                     未做循环展开
Performance counter stats for './vexp':
                                                                     汇编规模50行
                                               0.988 CPUs utilized
          56.84 msec task-clock:u
                                                                     IPC ~1.28
                                               0.000 K/sec
             0 context-switches:u
                                               0.000 K/sec
                    cpu-migrations:u
                                               0.008 M/sec
                    page-faults:u
                                               2.384 GHz
                    cvcles:u
                                               1.28 insn per cycle
     173,681,547
                    instructions:u
     0.057522960 seconds time elapsed
     0.049852000 seconds user
     0.007677000 seconds sys
Performance counter stats for './vexp unroll':
                                                                     循环展开
                                            # 0.991 CPUs utilized
           42.64 msec task-clock:u
                                                                     汇编规模190行
                                           # 0.000 K/sec
                    context-switches:u
                                           # 0.000 K/sec
                    cpu-migrations:u
                                                                     IPC ~1.59
                                           # 0.001 M/sec
                    page-faults:u
                                            # 2.517 GHz
     107,324,851
     170,681,504
                                            # 1.59 insn per cycle
                    branch-misses:u
     0.043041660 seconds time elapsed
     0.042992000 seconds user
     0.0000000000 seconds sys
```

上述例子为使用编译选项-funroll-loops进行循环展开;另外可手动对循环体进行展开,或者使用SIMD改写循环内容,均能在合适场景将循环性能进行提升



# 循环优化指南 之 SIMD优化

### 原理知识:

 SIMD(Single Instruction Multi Data)单指令多数据流,支持将数据 打包在一个大型寄存器中进行处理的一组指令集,在性能上相比标量操作吞吐量更大,适合数据密集型的操作;

### 使用方法:

- 编译器自动向量化优化,加入-ftree-vectorize,或编译优化设置为-O3,可添加-ftree-vectorizer-verbose参数查看编译器优化;
- 使用Neon Instrinsics改写循环体,优化处理过程;

```
static inline void vadd(int length, float* src)
 id vadd(int length, float* src)
                                                                       float32x4 t vsrc;
   for (int i = 0; i < length; i++) {
                                                                      float32x4_t vtemp;
                                                                      for (int i = 0; i < length / 4; i++) {
        src[i] += src[i] * src[i];
                                                                          vsrc = vldlq_f32(src + i * 4);
                                                                          vtemp = vmlaq f32(vsrc, vsrc, vsrc);
                                                                          vstlq f32(src + i * 4, vtemp);
 nt main(int argc, char **argv)
                                                                   int main(int argc, char **argv)
    float *src = (float *)malloc(100000000 * sizeof(float
                                                                       float *src = (float *)malloc(100000000 * sizeof(float*))
   for (int i = 0; i < 100000000; i++) {
                                                                       for (int i = 0; i < 100000000; i++) {
        src[i] = rand() * 100;
   vadd(100000000, src);
                                                                      vadd(100000000, src);
Performance counter stats for './vadd':
                                                     Performance counter stats for './vadd inline':
        2,299.48 msec task-clock:u
                                                              2,130.46 msec task-clock:u
                                                                                                        1.000 CPUs utilized
                                                                           context-switches:u
                     cpu-migrations:u
                                                 0.00
                                                                           cpu-migrations:u
                                                                                                         0.000 K/sec
                                                 0.16
                                                                                                        0.239 K/sec
                                                                           page-faults:u
   5,761,850,685
                                                 2.50
                                                        5,366,448,557
                                                                           cycles:u
                                                                                                        2.519 GHz
                                                                                                        1.43 insn per cycle
   7,690,540,540
                     instructions:u
                                                         7,690,540,553
                                                                           instructions:u
                     branches:u
                                                                           branches:u
      3,234,224
                    branch-misses:u
                                                             3,232,127
                                                                           branch-misses:u
     2.301245250 seconds time elapsed
                                                           2.131350040 seconds time elapsed
     2.244850000 seconds user
                                                           2.048101000 seconds user
     0.047914000 seconds sys
                                                           0.080029000 seconds sys
```



# 循环优化指南之合并小循环

### 原理知识:

- 对于小循环体,可以考虑将函数上下流中的多个循环 合并至一个循环内执行,减少对循环变量的操作;
- 合并小循环后也有利于增加Kunpeng处理器乱序执行的机会,提升指令级的并行能力。

### 注意:

- 循环的大小不绝对以代码规模而定,需要视循环的计算复杂性而言;
- 小循环内若均存在分支判断,则需要视情况而定,过多的分支可能会导致合并后性能劣化。

```
for (int i = 0; i < 1000000000; i++) {
      src[i] = rand();
 // Transform to [1Bound, rBound)
for (int i = 0; i < 100000000; i++) {
      src[i] = lBound + (rBound - lBound) * src[i];
Two loops:
2213 ms
 Performance counter stats for './trans':
        2.216.96 msec task-clock:u
                                                1.000 CPUs utilized
                                                 0.000 K/sec
                    context-switches:u
                                                 0.000 K/sec
                     cpu-migrations:u
                    page-faults:u
                                                0.477 K/sec
           1,057
    5,399,335,821
                                               2.435 GHz
    7,642,129,804
       3,244,608
                     branch-misses:u
      2.217507250 seconds time elapsed
      2.098436000 seconds user
      0.115771000 seconds sys
Merge loops:
2013 ms
Performance counter stats for './trans 1':
        2,017.17 msec task-clock:u
                                                 0.999 CPUs utilized
                     context-switches:u
                                                 0.000 K/sec
                                                 0.000 K/sec
                     cpu-migrations:u
                                                 0.349 K/sec
                     page-faults:u
    5,097,076,200
                                                 2.527 GHz
    7,642,129,806
                     instructions:u
                                                 1.50 insn per cycle
                     branches:u
       3,245,118
                     branch-misses:u
      2.018326200 seconds time elapsed
     1.950886000 seconds user
      0.063984000 seconds sys
```

```
10.0 20.0
Two loops:
2281 ms
Merge loops:
2186 ms
```

以生成[lBound, rBound)的均匀分布随机数为例,首先生成[0, 1)均匀分布随机数,然后通过分布转换将数据映射到对应的空间。

操作相对简单,可做循环合并,增加 指令的并行能力和乱序执行的可能, 从微观数据来看IPC利用率更高。



# 循环优化指南 之 拆分大循环

### 原理知识:

- 针对较为复杂或计算密集的循环,可以将大循环拆分至多个小循环内执行,可以提升寄存器的利用效率;
- 拆分大循环与合并小循环的使用是相对概念,难以绝对而言。

以生成标准高斯分布随机数为例,首先生成两个[0, 1)均匀分布随机数,然后通过BoxMuller分布转换方法将数据映射到对应的空间;其中BoxMuller方法需要使用Ln、Sqrt和Sin操作,属于计算密集操作。

在实际案例中,将循环拆分后性能得到大幅度提升(业务场景性能提升200%),减轻同一个循环的计算密度,提升寄存器的利用效率,同时也在一定程度上减少page-faults。

```
for (int i = 0; i < 100000000; i++)
     src[i] = sqrt(-2 * log(rand())) * sin(2 * 3.1415926 * rand());
Merge loops:
21106 ms
Performance counter stats for './trans 1':
       21,109.45 msec task-clock:u
                                                 1.000 CPUs utilized
                                                  0.000 K/sec
                     context-switches:u
                     cpu-migrations:u
                                                 0.000 K/sec
                                                 0.069 K/sec
           1,449
                     page-faults:u
   54,398,614,358
                                                  2.577 GHz
                     cycles:u
   87,046,315,419
                     instructions:u
                                                  1.60 insn per cycle
                     branches:u
      205,055,486
                     branch-misses:u
     21.112294430 seconds time elapsed
     20.939576000 seconds user
      0.131779000 seconds sys
for (int i = 0; i < 100000000; i++) {
    src[i] = sin(2 * 3.1415926 * rand());
for (int i = 0; i < 100000000; i++) {_
    src[i] *= sqrt(-2 * log(rand()));
Two loops:
20450 ms
Performance counter stats for './trans':
        20,451.83 msec task-clock:u
                                                  1.000 CPUs utilized
                     context-switches:u
                                                  0.000 K/sec
                                                  0.000 K/sec
                     cpu-migrations:u
                     page-faults:u
                                                  0.022 K/sec
   52,854,526,474
                                                  2.584 GHz
   86,596,010,231
                     instructions:u
                                                  1.64 insn per cycle
                     branches:u
      194,837,063
                     branch-misses:u
     20.454634500 seconds time elapsed
     20.367134000 seconds user
```



0.035933000 seconds sys

# 语句优化指南 之 减少内存读写和分配

### 原理知识:

- 使用临时变量等手段,减少对某一块固定内存空间的访问,可以提升编译器的优化能力;
- 针对一些场景,可以重复利用内存空间,减少分配内存的次数来进行性能提升。

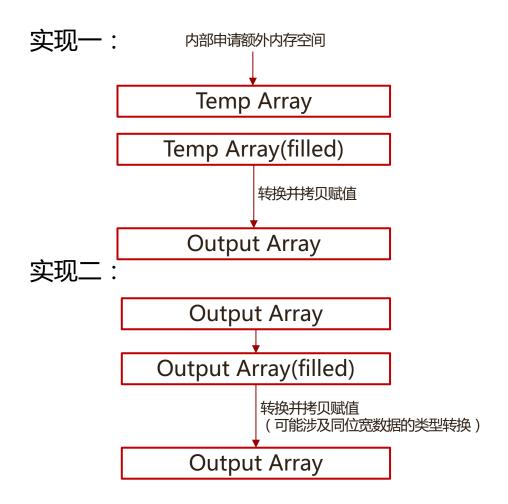
在某案例中,生成最终输出数据的流程包含前端和后端转换,在编码实现时实际上有两种实现模式:

一种是内部分配内存A用于存放算法核心生成的数据内容,转换赋值至目标内存空间B内;

另一种是直接用目标数组空间B作为中间存储,转换赋值在内存空间B内进行。

前者内存模式为copy,且需要内部分配空间,在输出长度较大时带来额外开销;后者内存模式为override,无需分配额外空间,经实测override的带宽也比copy的带宽更高。

端到端性能提升10%。





# 语句优化指南 之 结构体对齐

### 原理知识:

尽量保持结构体的定义保持字节对齐,有利于在编译器优化后运行时性能最佳,避免内存不对齐。

### 优化方法:

- 较小结构体进行机器字对齐,较大结构体进行Cache Line对齐
   (L1/L2 64Bytes, L3 128Bytes);
- 只读字段与读写字段隔离对齐,使得其集中在Cache的不同Cache Line中,降低只读字段的Cache Line频繁失效,也减少读写字段污染的Cache Line条数;
- 尽量大数据类型在前,小数据类型在后,保持数据紧密;
- 总字节数尽量是2的幂次;
- 每个域的起始地址为其大小的整数倍;
- 可以使用编译器提供的按字节对齐的编译原句\_\_attribute\_\_((aligned(x))), \_\_attribute\_\_(packed())优化。

```
static void real_job(int index)
 define VAR NR ((CACHE LINE SIZE/sizeof(int))-1)
truct key {
                                                                 struct key *k = g key+index;
    int a [VAR NR];
   // int pad;
                                                                 for (i = 0; i < VAR NR; ++i) {
   attribute ((packed));
                                                                     k\rightarrow a[i] = i;
Performance counter stats for './no padd':
                                                                 for (i = 0; i < LOOP NR; ++i)
        7.447.52 msec task-clock
                                              # 43.171 CPUs
                                                                     k->a[14] = k->a[14]+k->a[3];
                     context-switches
                                                 0.025 K/sec
                                                                     k->a[3] = k->a[14]+k->a[5];
                                                 0.013 K/sec
                     cpu-migrations
                                                                     k \rightarrow a[1] = k \rightarrow a[1] + k \rightarrow a[7];
                                                 0.034 K/sec
                    page-faults
                                                                     k->a[7] = k->a[1]+k->a[9];
  19,360,124,525
                                                  2.600 GHz
                     cycles
  57,671,033,860
                     instructions
                                                  2.98 insn
                     branches
         175,570
                     branch-misses
     0.172513250 seconds time elapsed
                                             结构体未对齐
     7.439424000 seconds user
     0.000000000 seconds sys
Performance counter stats for './padd':
        7,446.00 msec task-clock
                                                 44.235 CPUs utilized
                                                  0.021 K/sec
                     context-switches
                                                  0.013 K/sec
                     cpu-migrations
                     page-faults
                                                  0.034 K/sec
   19,356,618,927
                                                  2.600 GHz
                     cycles
   57,664,918,542
                                                  2.98 insn per cycle
                     instructions
         163,157
                     branch-misses
                                                 结构体对齐
     0.168329850 seconds time elapsed
     7.434411000 seconds user
     0.004068000 seconds sys
```

如上图所示,结构体构造为CacheLine大小减去一个整形数据的大小,进行数据更新的操作。CPU在进行数据获取和更新操作时,由于结构体与Cache Line Size的匹配关系,直接影响了cache是否会产生失效。



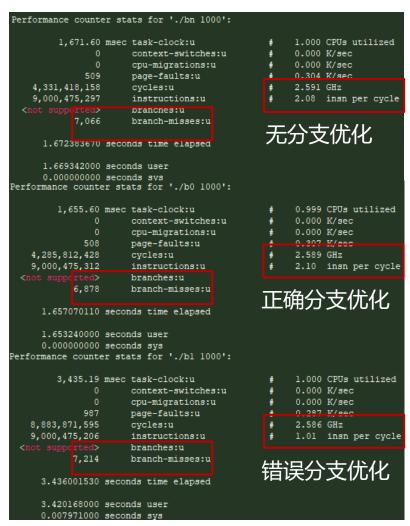
# 语句优化指南 之 分支优化

### 原理知识:

编译器会对分支进行预判,正确的编码方式可以提高分支预测的准确性和流水线效率;

### 优化方法:

- 避免将判断放在循环内;
- 拆分循环,将循环内的多条件分支运行拆分成多个循环,避免判断(例如奇偶拆分);
- 合并条件,多个条件合并成一个分支预测;
- 使用三目条件运算符,编译器将优化会条件赋值语句,可以提升性能;
- 使用查表的方式减少分支;
- 调整判断顺序或使用unlikely()/likely()语句显性标识分支可能性,提升编译器对分支预测的准确性。



针对同一程序代码,添加unlikely()/likely()语句实际运行结果



# 多线程并发优化指南 之避免不必要共享写

### · 原理

- 多核写入共享变量会导致所在cache line在这些核的私有cache之间重复 无效化,降低cache命中率
- 伪共享:写入位于相同cache line的不同变量,和写入共享变量效果相同

### • 鲲鹏特点

■ 鲲鹏920的L1和L2 cache line大小为64字节、L3 cache line为128字节

### · 优化方案

- OpenMP代码中使用reduction子句替代直接写入共享变量(循环过程中写入线程私有变量)
- 线程私有的变量按照cache line大小对齐(线程栈上的变量除外)
- 使用线程私有变量(如GCC支持\_\_thread,C11支持\_Thread\_local关键字)

### ・ 优化例1(见右上)

- 增加reduction子句, 当n=1G时运行时间缩短到2/3
- ・ 优化例2(见右下)
  - 对于线程私有的变量增加按照cache对齐,100线程下运行时间缩短到1/3

```
int domainError = 0;
#pragma omp parallel for reduction(|:domainError)
  for (long i = 0; i < n; i++) {
     if (a[i] <= 0) {
        domainError = 1;
     }
     y[i] = logf(a[i]);
}
return domainError;</pre>
```

```
struct ThreadInfo {
    unsigned long tid;
    float *input;
    unsigned long sum;
    unsigned long length;
} __attribute__ ((aligned (128)));

struct ThreadInfo tinfo[N];

void *proc(void *arg)
{
    struct ThreadInfo *info = (struct ThreadInfo *)arg;
    info->sum = 0;
    for (unsigned long i = 0; i < info->length; i++) {
        info->sum += info->input[i];
    }
}
```



# 调优工具 (perf)

- perf可以在运行程序时收集性能计数器(events),分析程序性能、发现热点或性能瓶颈
  - 列出perf支持的events: perf list
  - 运行app并收集events信息,运行结束后输出结果:perf stat -c events./app
    - □ 例如右上例在运行/bin/ls时收集了cycles(CPU时间)和cache-misses信息
  - 运行app并收集信息后存入文件: perf record -c events ./app , 然后可用perf report查看
    - 例如右例是使用perf report后可见的界面,给出每个函数的 cycles事件分布
    - □ 根据此比例发现程序热点,决定首先优化的函数
    - 进入具体函数后可以看到每条指令的cycles分布,可以看到str指令为热点
      - 注:编译时需要加入调试信息才能显示C源代码(GCC使用-g)

```
[251 1.48 opt]$ perf stat -e cycles, cache-misses /bin/ls /
bin dev home lib64 media opt root sbin sys usr
boot etc lib lost+found mnt proc run srv tmp var

Performance counter stats for '/bin/ls /':

909159 cycles:u

5112 cache-misses:u

0.001482320 seconds time elapsed

0.001525000 seconds user
0.00000000000 seconds sys
```

mples: 972 of event 'cycles:u', Event count (approx.

```
Command Shared Object
                                  Symbol 5
                                   [.] getx
       ins
                                   .] main
                ins
0.10%
       ins
                libc-2.28.so
                                   .] IO file xsput
               1d-2.28.so
                                      _dl_lookup_sym
0.02%
       ins
                1d-2.28.so
                                   .] dl start fina
0.00%
       ins
                                     dl start
0.00% ins
                1d-2.28.so
           return __builtin_aarch64_ld1v4sf ((const
         vmulq f32():
          return __a * __b;
1.03
         main():
            for (int i = 0; i < N; i += 4) {
         vst1q_f32():
          extension extern inline void
         attribute (( always inline , gnu
         vst1q f32 (float32 t *a, float32x4 t b)
           __builtin_aarch64_st1v4sf ((__builtin_aa
         main():
```

# 调优工具优化举例:perf

- 优化前perf发现访存指令 所用CPU cycles较多,考 虑优化访存
- 优化方法:交换内外层循环,提高数组B访问局部性
- 优化后性能明显提升且 perf统计发现数组B加载 指令不再是热点

# 优化前

```
for (int i = 0; i < N; i++) {
    for (int j = 0; j < P; j++) {
        C[i][j] = 0;
        for (int k = 0; k < M; k++) {
            C[i][j] += A[i][k] * B[k][j];
                        x1, x6
    5.20
0.10
8.85
5.00
                                            加载
                                           数组B
                        s0, s2, s1, s0
    0.60
               ↑ b.ne
    0.06
                        s0, [x5, x4]
                 str
                        x4, x4, #0x4
                 add
```

### 优化后

```
for (int k = 0; k < M; k++) {
       for (int j = 0; j < P; j++)
           if (k == 0) {
               C[i][j] = 0;
           C[i][j] += A[i][k] * B[k][j];
                   s2, [x5, x2, 1s1 #2]
                   x0, #0x0
0.60 30: ↓ cbz
                   x2, 78
                                      加载
0.06
                   s1, [x1, x0]
                                     数组B
     38:
                  s0, s2, s0, s1
                  x0, x0, #0x4
                   x0, x4
```

